

UNIVERSIDAD DEL VALLE DE GUATEMALA
Facultad de Ingeniería



Laboratorio 4: Extracción lingüística con Hugging Face

Sentimiento y entidades nombradas en reseñas de Barça Cafe

Diego Linares
Procesamiento de Lenguaje Natural

Septiembre de 2026

Introducción

¿Qué tan bien funcionan los modelos preentrenados de Hugging Face cuando se les da reseñas reales en español, sin ajustar nada?

Para responderlo se construyó un pipeline con `transformers` (Wolf et al., 2020) sobre reseñas de **Barça Cafe**, el restaurante oficial del FC Barcelona junto al Spotify Camp Nou. El pipeline clasifica el sentimiento de cada reseña (Parte A), extrae entidades nombradas (Parte B), junta ambas salidas en una estructura por reseña (Parte C), calcula estadísticas y exporta `laboratorio_4_resultados.csv` (Parte D), y analiza los casos en los que el modelo se equivoca (Parte E).

El restaurante no se eligió al azar. En Google Maps tiene 3.2 estrellas con opiniones muy polarizadas: a mucha gente le encanta la decoración y a mucha otra le parece caro y mediocre. Eso garantiza reseñas positivas, negativas y mixtas, que es justo lo que pide la guía.

Este documento es el notebook `laboratorio_4_barca_cafe.ipynb` en formato de reporte: se incluyen las celdas de código, sus salidas y el análisis. Las tablas muy anchas del notebook se presentan aquí como tablas de $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$ con las mismas cifras. El código completo está en <https://github.com/DiegoLinares11/LAB-4-Extraccion-Linguistica-Con-Hugging-Face>.

1. Dataset

Las reseñas se basan en la ficha de Barça Cafe en Google Maps (Carrer d'Arístides Maillol 12, Les Corts, Barcelona), consultada el 14 de septiembre de 2026 (Google, s.f.). Tiene **3.2 estrellas con 424 opiniones** y esta distribución:

Estrellas	5	4	3	2	1
Opiniones	176	33	34	44	137

Por qué no se copiaron las reseñas literales

La guía pide no incluir datos personales reales, y una reseña de Google Maps no es solo texto: trae el nombre del autor, su foto, su perfil de *Local Guide* y la fecha. Además el texto pertenece a quien lo escribió, y los Términos de Servicio de Google Maps no permiten extraer ese contenido para reutilizarlo. Por eso el dataset se armó así:

- **6 reseñas son paráfrasis** de las opiniones que Google Maps muestra públicamente: los tres fragmentos destacados del resumen y las tres reseñas visibles sin iniciar sesión. Se reescribieron con otras palabras y sin autor, conservando la opinión: café frío, café caro y baños sucios, vaso de plástico cobrado sin avisar, hamburguesa “1/10”, camareras amables, comida exquisita.
- **30 reseñas son simuladas** a partir de los temas reales que Google detecta en las 424 opiniones: *hamburguesa* (54 menciones), *barça* (41), *mesa* (18), *cerveza* (16), *estadio* (10), *baños* (9), *vaso de plástico* (7).
- **Todos los nombres de clientes y empleados son ficticios** (Nuria, Sergi, Santiago, Mateo). Se mantienen organizaciones y lugares públicos (FC Barcelona, Real Madrid,

Les Corts, Guatemala) y dos referencias públicas del restaurante: el jugador Lamine Yamal y los hermanos Iglesias, a quienes el club anunció como responsables de la carta (FC Barcelona, 2021). No son datos privados y hacen falta para probar el NER con personas.

Etiqueta humana y cobertura

Antes de correr cualquier modelo, a cada reseña se le asignó una `etiqueta_humana` y una lista de casos. Esa etiqueta es la referencia contra la que se comparan los modelos.

```
df_resenas = pd.read_csv(DATOS)
assert len(df_resenas) >= 30, "La guía pide un mínimo de 30 reseñas"

print(f"{len(df_resenas)} reseñas | columnas: {list(df_resenas.columns)}\n")
df_resenas[["review_id", "text", "etiqueta_humana", "estrellas", "casos"]]
```

```
36 reseñas | columnas: ['review_id', 'text', 'etiqueta_humana', 'estrellas', 'casos', 'tema', 'origen']
↪ ']
```

```
cobertura = (df_resenas.assign(caso=df_resenas["casos"].str.split(";"))
              .explode("caso")["caso"].value_counts().rename("reseñas"))

print("Etiqueta humana:")
print(df_resenas["etiqueta_humana"].value_counts().to_string(), "\n")
print("Origen:")
print(df_resenas["origen"].value_counts().to_string(), "\n")
print("Tipos de caso cubiertos:")
print(cobertura.to_string())
```

Etiqueta humana	Reseñas
POSITIVO	15
NEGATIVO	14
MIXTO	5
NEUTRO	2

Tipo de caso	Reseñas
entidades	14
positivo	9
negativo	7
negacion	6
mixto	5
texto_corto	4
sarcasmo	3
error_ortografico	2
neutro	2
mixto_leve	1
entidad_desconocida	1
jerga	1
mezcla_idiomas	1

El dataset completo (36 reseñas) queda así; “Hum.” es la etiqueta humana y “Est.” la estrella simulada:

ID	Reseña	Hum.	Est.	Casos
1	Fuimos después del tour del Museo del FC Barcelona y nos encantó. La decoración azulgrana, las pantallas gigantes y unos camareros muy agradables. Muy recomendable.	POS	5	positivo, entidades
2	La camarera Nuria nos atendió de maravilla, súper simpática y rápida. La comida muy rica y el sitio precioso.	POS	5	positivo, entidades
3	Pedí dos cafés y un croissant de chocolate y me lo sirvieron todo frío. Para estar dentro del estadio esperaba bastante más.	NEG	1	negativo
4	Tres euros y medio por un café mediocre. Encima los baños estaban sucios a mediodía de un martes cualquiera. El FC Barcelona debería cuidar más sus instalaciones.	NEG	1	negativo, entidades
5	El chico de la caja fue muy amable, eso sí. Lo que me molestó es que te cobran el vaso de plástico sin avisarte ni darte otra opción.	MIX	2	mixto
6	Voy probando hamburguesas por todo Barcelona y esta es de las peores: pan seco y carne sin sabor. Un 1 sobre 10.	NEG	1	negativo, entidades
7	Un sitio precioso para visitar, la comida riquísima y el personal muy atento.	POS	5	positivo
8	Vimos el clásico del Barça contra el Real Madrid en las pantallas gigantes. Ambiente espectacular y la Estrella Damm bien fría.	POS	5	positivo, entidades
9	Genial, 40 minutos esperando una hamburguesa que llegó fría. Una experiencia inolvidable, de verdad.	NEG	1	sarcasmo
10	No volvería. No es que la comida sea horrible, pero no vale lo que cuesta.	NEG	2	negacion
11	No está nada mal para ser un sitio turístico. Las bravas no tienen nada que envidiar a las de cualquier bar de Les Corts.	POS	4	negacion, entidades
12	Top!!	POS	5	texto corto
13	Carísimo.	NEG	1	texto corto
14	La decoración con camisetas firmadas y lámparas en forma de balón es preciosa, pero la comida es muy normalita y cara.	MIX	3	mixto
15	no bale la pena, la amburguesa estava cruda i el refresco sin gas. nunca mas	NEG	1	error ortografico, negacion
16	q buen sitio!! los nachos buenisimos y el camarero super atento, bolveremos seguro	POS	5	error ortografico
17	Está junto al Palau Blaugrana, en la calle Arístides Maillol. Abren a las 10 de la mañana.	NEU	3	neutro, entidades
18	Vinimos desde Guatemala solo para conocer el Spotify Camp Nou y comer aquí fue la guinda. Mi hijo Santiago salió feliz con su camiseta de Lamine Yamal.	POS	5	positivo, entidades
19	La carta la diseñaron los hermanos Iglesias y se nota en algunos platos, pero el servicio no está a la altura: tardaron muchísimo.	MIX	3	mixto, entidades
20	Nos tuvieron esperando de pie aunque había mesas libres. Cuando por fin nos sentamos, la mesa estaba pegajosa.	NEG	1	negativo
21	Buena opción para comer algo rápido antes del partido. Precios de estadio, pero la calidad es correcta y el personal eficiente.	POS	4	positivo, mixto leve

ID	Reseña	Hum.	Est.	Casos
22	Qué suerte tenemos los culés: pagar siete euros por una cerveza en vaso de plástico. Así seguro que terminan la reforma del estadio.	NEG	2	sarcasmo
23	Los camareros son un amor, pero la cocina es un desastre: el pollo seco y las patatas congeladas.	MIX	2	mixto
24	Celebramos el cumpleaños de mi sobrino Mateo aquí y el equipo del Barça Cafe se portó genial, hasta le pusieron una vela en el postre.	POS	5	positivo, entidades
25	Personal desbordado, música altísima y nadie limpió nuestra mesa en toda la tarde. Una pena para la imagen del club.	NEG	1	negativo
26	Meh.	NEG	2	texto corto
27	No puedo decir que no me haya gustado: el bocadillo de jamón estaba bueno y no tardaron nada.	POS	4	negacion
28	Esperaba algo digno del Museu del Barça y me encontré un bar de aeropuerto con precios de Plaça de Catalunya.	NEG	1	negativo, entidades
29	La Blaugrana Burger con salsa Culé está brutal, pídanla sin dudar.	POS	5	entidad desconocida, jerga
30	Amazing ambiente, la paella muy good y el staff very friendly. ¡Volveremos desde México!	POS	5	mezcla idiomas, entidades
31	Pedí una ensalada y me trajeron una hamburguesa. Cuando lo reclamé, el encargado Sergi ni se disculpó.	NEG	1	negativo, entidades
32	Para ver un partido con amigos está bien, para comer no lo recomiendo.	MIX	3	mixto, negacion
33	El brunch del domingo fue una sorpresa: huevos benedictinos riquísimos, zumo natural y vistas al estadio.	POS	5	positivo
34	Cinco estrellas... para el aire acondicionado, que es lo único que funcionaba.	NEG	1	sarcasmo
35	Normal. Ni bueno ni malo.	NEU	3	neutro, negacion, texto corto
36	Coincidimos con aficionados de Japón y Brasil y acabamos todos cantando el himno del Barça. Ambiente único en Barcelona.	POS	5	positivo, entidades

2. Configuración

La primera celda instala solo las dependencias que falten, para que el notebook corra igual en Colab que en local. La segunda carga las librerías, apaga las barras de progreso y detecta la GPU.

```
# !pip install -q transformers torch pandas
# La celda instala solo lo que falte, así el notebook corre igual en Colab que en
  ↪ local.
import importlib.util
import subprocess
import sys

_faltantes = [p for p in ("transformers", "torch", "pandas", "matplotlib")
               if importlib.util.find_spec(p) is None]
if _faltantes:
    subprocess.check_call([sys.executable, "-m", "pip", "install", "-q", *_faltantes])
```

```
↩️ ]])
print("Dependencias listas." if not _faltantes else f"Instalado: {_faltantes}")
```

```
from pathlib import Path
import json
import warnings

import pandas as pd
import matplotlib.pyplot as plt
import torch
import transformers

from huggingface_hub.utils import disable_progressBars
from huggingface_hub.utils import logging as hf_logging
from transformers import pipeline
from transformers.utils import logging as hf_logging

warnings.filterwarnings("ignore")
hf_logging.set_verbosity_error()
hf_logging.disable_progress_bar()
hf_logging.set_verbosity_error()
disable_progressBars()
pd.set_option("display.max_colwidth", 120)
pd.set_option("display.width", 220)
pd.set_option("display.max_rows", 100)

RAIZ = Path.cwd()
DATOS = RAIZ / "data" / "resenas_barca_cafe.csv"
RESULTADOS = RAIZ / "resultados"
FIGURAS = RESULTADOS / "figuras"
FIGURAS.mkdir(parents=True, exist_ok=True)

DEVICE = 0 if torch.cuda.is_available() else -1
BATCH = 8

print("transformers:", transformers.__version__)
print("torch          :", torch.__version__)
print("dispositivo  :", torch.cuda.get_device_name(0) if DEVICE == 0 else "CPU")
```

```
transformers: 5.14.1
torch          : 2.10.0+cu128
dispositivo  : NVIDIA GeForce RTX 4060 Laptop GPU
```

3. Parte A: análisis de sentimiento

A.1 Pipeline por defecto

Primero, exactamente la llamada que pide la guía: `pipeline("sentiment-analysis")` sin indicar de modelo. Conviene imprimir cuál elige transformers, porque de eso depende todo lo demás.

```
sentiment = pipeline("sentiment-analysis", device=DEVICE)

print("modelo      :", sentiment.model.name_or_path)
print("etiquetas   :", sentiment.model.config.id2label)
```

```

modelo      : distilbert/distilbert-base-uncased-finetuned-sst-2-english
etiquetas   : {0: 'NEGATIVE', 1: 'POSITIVE'}

```

```

reseñas = df_resenas["text"].tolist()
ids = df_resenas["review_id"].tolist()

resultados = sentiment(reseñas, batch_size=BATCH, truncation=True)

df_sent_defecto = pd.DataFrame({
    "review_id": ids,
    "text": reseñas,
    "label": [r["label"] for r in resultados],
    "score": [round(float(r["score"]), 4) for r in resultados],
})
df_sent_defecto

```

Primeras filas de la salida (las 36 aparecen en la tabla de la Parte D):

ID	Texto	Etiqueta	Score
1	Fuimos después del tour del Museo del FC Barcelona y nos encantó. La decoración azulgrana, las pantallas gigantes y unos camareros muy agradables. Muy recomendable.	POSITIVE	0.9388
2	La camarera Nuria nos atendió de maravilla, súper simpática y rápida. La comida muy rica y el sitio precioso.	NEGATIVE	0.9494
3	Pedí dos cafés y un croissant de chocolate y me lo sirvieron todo frío. Para estar dentro del estadio esperaba bastante más.	NEGATIVE	0.9497
4	Tres euros y medio por un café mediocre. Encima los baños estaban sucios a mediodía de un martes cualquiera. El FC Barcelona debería cuidar más sus instalaciones.	NEGATIVE	0.9845
5	El chico de la caja fue muy amable, eso sí. Lo que me molestó es que te cobran el vaso de plástico sin avisarte ni darte otra opción.	NEGATIVE	0.9827
6	Voy probando hamburguesas por todo Barcelona y esta es de las peores: pan seco y carne sin sabor. Un 1 sobre 10.	NEGATIVE	0.9561

El modelo por defecto es DistilBERT (Sanh et al., 2019) afinado sobre SST-2, un corpus de reseñas de cine **en inglés** con solo dos clases (Socher et al., 2013). No tiene clase **NEUTRAL**, así que las reseñas mixtas y neutras quedan forzadas a un polo. Además, su vocabulario en inglés no conoce la mayoría de las palabras en español. Ya en la segunda fila aparece el problema: “nos atendió de maravilla, súper simpática” sale **NEGATIVE** con 0.95.

A.2 Modelo multilingüe entrenado con reseñas

Para tener una comparación justa se repitió el análisis con `nlptown/bert-base-multilingual-uncased-sentiment` (NLP Town, s.f.). Es un BERT multilingüe (Devlin et al., 2019) afinado con reseñas de producto en seis idiomas, entre ellos el español, y devuelve de 1 a 5 estrellas. Se mapea a tres clases: 1–2 → **NEGATIVE**, 3 → **NEUTRAL** y 4–5 → **POSITIVE**.

El score tiene un detalle: con cinco clases, la probabilidad se reparte entre estrellas vecinas. Una reseña claramente positiva puede salir “5 estrellas con 0.30” porque otro 0.25 se

fue a 4. Por eso se pide la distribución completa (`top_k=None`) y se guarda también `score_polaridad`, la probabilidad *sumada* de todas las estrellas de esa polaridad.

```
MODELO_SENT_ES = "nlptown/bert-base-multilingual-uncased-sentiment"

sentiment_es = pipeline("sentiment-analysis", model=MODELO_SENT_ES, device=DEVICE)
print("etiquetas :", sentiment_es.model.config.id2label)

def normalizar_sentimiento(etiqueta: str) -> str:
    '''Lleva las etiquetas de cualquier modelo a POSITIVE / NEGATIVE / NEUTRAL.'''
    e = etiqueta.lower()
    if "star" in e:
        n = int(e.split()[0])
        return "NEGATIVE" if n <= 2 else "NEUTRAL" if n == 3 else "POSITIVE"
    if "pos" in e:
        return "POSITIVE"
    if "neg" in e:
        return "NEGATIVE"
    return "NEUTRAL"

def resumir_distribucion(distribucion):
    '''`distribucion` es la salida con top_k=None (todas las clases, ordenadas por
    ↪ score).
    Devuelve (polaridad, etiqueta ganadora, score ganador, score sumado de la
    ↪ polaridad).'''
    top = distribucion[0]
    polaridad = normalizar_sentimiento(top["label"])
    score_polaridad = sum(d["score"] for d in distribucion
                          if normalizar_sentimiento(d["label"]) == polaridad)
    return polaridad, top["label"], float(top["score"]), float(score_polaridad)

resultados_es = sentiment_es(reseñas, batch_size=BATCH, truncation=True, top_k=None)
resumen_es = [resumir_distribucion(d) for d in resultados_es]

df_sent_es = pd.DataFrame({
    "review_id": ids,
    "text": reseñas,
    "label": [r[0] for r in resumen_es],
    "score": [round(r[2], 4) for r in resumen_es],
    "label_original": [r[1] for r in resumen_es],
    "score_polaridad": [round(r[3], 4) for r in resumen_es],
})
df_sent_es
```

```
| etiquetas : {0: '1 star', 1: '2 stars', 2: '3 stars', 3: '4 stars', 4: '5 stars'}
```

Primeras filas de la salida:

ID	Texto	Etiqueta	Estrellas	Score	Polaridad
1	Fuimos después del tour del Museo del FC Barcelona y nos encantó. La decoración azulgrana, las pantallas gigantes y unos camareros muy agradables. Muy recomendable.	POSITIVE	5 ★	0.8571	0.9924
2	La camarera Nuria nos atendió de maravilla, súper simpática y rápida. La comida muy rica y el sitio precioso.	POSITIVE	5 ★	0.8596	0.9888
3	Pedí dos cafés y un croissant de chocolate y me lo sirvieron todo frío. Para estar dentro del estadio esperaba bastante más.	NEGATIVE	2 ★	0.3717	0.5224
4	Tres euros y medio por un café mediocre. Encima los baños estaban sucios a mediodía de un martes cualquiera. El FC Barcelona debería cuidar más sus instalaciones.	NEGATIVE	1 ★	0.5659	0.9039
5	El chico de la caja fue muy amable, eso sí. Lo que me molestó es que te cobran el vaso de plástico sin avisarte ni darte otra opción.	NEUTRAL	3 ★	0.4382	0.4382
6	Voy probando hamburguesas por todo Barcelona y esta es de las peores: pan seco y carne sin sabor. Un 1 sobre 10.	NEGATIVE	1 ★	0.8476	0.9630

A.3 Comparación rápida entre ambos modelos

```

MAPA_HUMANO = {"POSITIVO": "POSITIVE", "NEGATIVO": "NEGATIVE", "NEUTRO": "NEUTRAL",
               ↪ "MIXTO": "MIXED"}

comparacion = pd.DataFrame({
    "review_id": ids,
    "humano": df_resenas["etiqueta_humana"].map(MAPA_HUMANO),
    "defecto": df_sent_defecto["label"],
    "score_defecto": df_sent_defecto["score"],
    "multilingue": df_sent_es["label"],
    "estrellas": df_sent_es["label_original"],
    "score_multi": df_sent_es["score"],
    "score_polaridad": df_sent_es["score_polaridad"],
    "text": reseñas,
})
comparacion["acierta_defecto"] = comparacion["humano"] == comparacion["defecto"]
comparacion["acierta_multi"] = comparacion["humano"] == comparacion["multilingue"]

polares = comparacion[comparacion["humano"].isin(["POSITIVE", "NEGATIVE"])]
print(f"Reseñas polares (POS/NEG según humano): {len(polares)}")
print(f"  aciertos modelo por defecto : {polares['acierta_defecto'].sum()} / {len(
    ↪ polares)}")
print(f"  aciertos modelo multilingüe : {polares['acierta_multi'].sum()} / {len(
    ↪ polares)}")
print(f"  ambos modelos coinciden      : {(comparacion['defecto'] == comparacion['
    ↪ multilingue']).sum()} / {len(comparacion)} reseñas")

comparacion.to_csv(RESULTADOS / "a_comparacion_sentimiento.csv", index=False)

```

```
comparacion.drop(columns="text")
```

```
Reseñas polares (POS/NEG según humano): 29
  aciertos modelo por defecto : 16 / 29
  aciertos modelo multilingüe : 21 / 29
  ambos modelos coinciden    : 20 / 36 reseñas
```

Con solo contar aciertos ya se nota la diferencia: el modelo multilingüe acierta 21 de las 29 reseñas polares y el modelo por defecto, 16. La tabla fila por fila está en la Parte D.

4. Parte B: reconocimiento de entidades nombradas

B.1 Pipeline por defecto

De nuevo, primero la llamada literal de la guía. Las etiquetas dependen del modelo, así que se imprimen en lugar de suponerlas.

```
ner = pipeline("token-classification", aggregation_strategy="simple", device=DEVICE)

print("modelo      :", ner.model.name_or_path)
print("etiquetas  :", sorted(set(ner.model.config.id2label.values())))
```

```
modelo      : dbmdz/bert-large-cased-finetuned-conll03-english
etiquetas  : ['B-LOC', 'B-MISC', 'B-ORG', 'B-PER', 'I-LOC', 'I-MISC', 'I-ORG', 'I-PER', 'O']
```

El modelo por defecto es un BERT *large* afinado sobre CoNLL-2003, que son noticias en inglés (Tjong Kim Sang & De Meulder, 2003). La función `extraer_entidades` toma el texto de cada entidad del span original (`start:end`), que es más fiel que el campo `word` que reconstruye el tokenizador.

```
def extraer_entidades(ner_pipe, textos, ids):
    '''Una fila por entidad. El texto se toma del span original (start:end), que es
    ↪ más
    fiel que el campo `word` reconstruido por el tokenizador.'''
    filas = []
    for rid, texto, ents in zip(ids, textos, ner_pipe(textos, batch_size=BATCH)):
        for e in ents:
            filas.append({
                "review_id": rid,
                "label": e["entity_group"],
                "text": texto[e["start"]:e["end"]],
                "word_modelo": e["word"],
                "score": round(float(e["score"]), 4),
                "start": e["start"],
                "end": e["end"],
            })
    return pd.DataFrame(filas, columns=["review_id", "label", "text", "word_modelo",
    ↪ "score", "start", "end"])

df_ner_defecto = extraer_entidades(ner, reseñas, ids)
print(f"{len(df_ner_defecto)} entidades en {df_ner_defecto['review_id'].nunique()}
    ↪ reseñas")
print(df_ner_defecto["label"].value_counts().to_string())
```

```
df_ner_defecto
```

```
46 entidades en 20 reseñas
label
ORG      14
LOC      13
PER      11
MISC      8
```

B.2 Modelo NER en español

mrm8488/bert-spanish-cased-finetuned-ner (Romero, s.f.) es BETO, un BERT entrenado en español (Cañete et al., 2020), afinado sobre CoNLL-2002 en español (Tjong Kim Sang, 2002) con las clases PER, ORG, LOC y MISC. Se corre con la misma agregación que pide la guía, `simple`.

```
MODELO_NER_ES = "mrm8488/bert-spanish-cased-finetuned-ner"

ner_es = pipeline("token-classification", model=MODELO_NER_ES,
                  aggregation_strategy="simple", device=DEVICE)
print("etiquetas :", sorted(set(ner_es.model.config.id2label.values())))

df_ner_es = extraer_entidades(ner_es, reseñas, ids)
print(f"{len(df_ner_es)} entidades en {df_ner_es['review_id'].nunique()} reseñas")
print(df_ner_es["label"].value_counts().to_string())
df_ner_es
```

```
etiquetas : ['B-LOC', 'B-MISC', 'B-ORG', 'B-PER', 'I-LOC', 'I-MISC', 'I-ORG', 'I-PER', 'O']
32 entidades en 15 reseñas
label
MISC      11
LOC       11
PER        6
ORG        4
```

B.3 Problema: entidades partidas en subpalabras

Al revisar las entidades aparecen cosas como Nu + ria, Spo + tify Camp Nou, Muse + u o Cul + é. La causa es la combinación del tokenizador con la estrategia `simple` (Hugging Face, s.f.):

- WordPiece parte las palabras poco frecuentes: Nuria → Nu ##ria.
- El modelo etiqueta cada subpalabra por separado. Si a ##ria le toca B-PER (inicio de entidad) en vez de I-PER, `simple` abre una entidad nueva a mitad de palabra.

La estrategia `first` agrega a nivel de palabra: toda la palabra toma la etiqueta de su primera subpalabra, así que ninguna palabra puede quedar partida. Se cuentan los fragmentos (entidades pegadas a una letra por la izquierda o por la derecha) con cada estrategia:

```
def es_fragmento(texto, start, end):
    return (start > 0 and texto[start - 1].isalnum()) or (end < len(texto) and texto
    ↪ [end].isalnum())
```

```
def contar_fragmentos(df_ner):
    textos = df_resenas.set_index("review_id")["text"]
    return sum(es_fragmento(textos[r.review_id], r.start, r.end) for r in df_ner.
    ↪ itertuples())

ner_es_first = pipeline("token-classification", model=MODELO_NER_ES,
                        aggregation_strategy="first", device=DEVICE)
df_ner_es_first = extraer_entidades(ner_es_first, reseñas, ids)

print(f'{'estrategia':<32}{'entidades':>10}{'fragmentos':>12}")
for nombre, d in [("defecto inglés, simple", df_ner_defecto),
                  ("español, simple", df_ner_es),
                  ("español, first", df_ner_es_first)]:
    print(f"{nombre:<32}{len(d):>10}{contar_fragmentos(d):>12}")
```

Estrategia	Entidades	Fragmentos
defecto inglés, simple	46	22
español, simple	32	8
español, first	27	0

```
def entidades_por_resena(df_ner):
    return (df_ner.assign(ent=df_ner["label"] + ":" + df_ner["text"])
            .groupby("review_id")["ent"].apply(" | ".join))

ner_lado_a_lado = pd.DataFrame({
    "text": df_resenas.set_index("review_id")["text"],
    "defecto (inglés, simple)": entidades_por_resena(df_ner_defecto),
    "español (simple)": entidades_por_resena(df_ner_es),
    "español (first)": entidades_por_resena(df_ner_es_first),
}).fillna("-")
ner_lado_a_lado = ner_lado_a_lado[(ner_lado_a_lado.iloc[:, 1:] != "-").any(axis=1)]
ner_lado_a_lado.to_csv(RESULTADOS / "b_comparacion_ner.csv")
ner_lado_a_lado
```

Entidades por reseña con cada enfoque (solo reseñas con al menos una entidad):

ID	Defecto (inglés, simple)	Español (simple)	Español (first)
1	LOC:del; ORG:FC Barcelona	MISC:Museo del FC Barcelona	MISC:Museo del FC Barcelona
2	PER:ca; PER:Nuria	PER:Nu; PER:ria	PER:Nuria
4	ORG:FC Barcelona	ORG:FC Barcelona	ORG:FC Barcelona
6	MISC:mb; MISC:ues; LOC:Barcelona	LOC:Barcelona	LOC:Barcelona
8	ORG:Barça; ORG:Real Madrid; ORG:Est; PER:rellam Damm	ORG:Barça; ORG:Real Madrid; MISC:Estrella Damm	ORG:Barça; ORG:Real Madrid; MISC:Estrella Damm
9	MISC:mb; MISC:ues	—	—
11	ORG:Les Corts	LOC:Les Corts	LOC:Les Corts
13	ORG:Carís	—	—

ID	Defecto (inglés, simple)	Español (simple)	Español (first)
15	MISC:ues	—	—
17	LOC:Palau; ORG:B; LOC:grana; LOC:Ar; PER:ístides Maillol; LOC:l	LOC:Palau Blaugrana; LOC:calle Arístides Maillol	LOC:Palau Blaugrana; LOC:calle Arístides Maillol
18	LOC:Guatemala; ORG:Spotify Camp; MISC:No; ORG:u; PER:Santiago; PER:Lamine Yamal	LOC:Guatemala; MISC:Spo; MISC:tify Camp Nou; PER:Santiago; MISC:Lamine Yamal	LOC:Guatemala; MISC:Spotify Camp Nou; PER:Santiago; MISC:Lamine Yamal
19	PER:Iglesias	PER:Iglesias	PER:Iglesias
23	PER:Los ca	—	—
24	PER:Mateo; ORG:Barça Cafe	PER:Mateo; ORG:Barça Cafe	PER:Mateo; ORG:Barça Cafe
26	PER:Me	—	—
28	ORG:Museu del Barça; LOC:Plaça de Catalunya	MISC:Muse; LOC:u; MISC:del Barça; LOC:Catalunya	MISC:Museu del Barça; LOC:Catalunya
29	ORG:La Blaugrana Burger	MISC:Blaugrana Burger; MISC:Cul; MISC:é	MISC:Blaugrana Burger; MISC:Culé
30	MISC:de; LOC:México	LOC:México	LOC:México
31	MISC:mb; PER:Sergi	PER:Sergi	PER:Sergi
36	LOC:Japón; LOC:Brasil; LOC:Bar; ORG:ça; LOC:Barcelona	LOC:Japón; LOC:Brasil; MISC:Ambiente único; LOC:Barcelona	LOC:Japón; LOC:Brasil; MISC:Ambiente único; LOC:Barcelona

Con **first** desaparecen todos los fragmentos y las entidades quedan legibles (Nuria, Spotify Camp Nou, Museu del Barça, Culé). Por eso **el flujo integrado usa el modelo en español con first**. Los errores que quedan ya no son de agregación sino del modelo: Lamine Yamal como MISC, Plaça de Catalunya reducida a Catalunya y Ambiente único marcado como entidad solo por empezar oración.

El modelo en inglés además inventa entidades con trozos de palabras en español: **del** como lugar, **ca** (de “camarera”) y **Me** (de “Meh.”) como personas, **Carís** como organización, y **mb/ues**, pedazos de “hamburguesa”, como MISC.

5. Parte C: flujo integrado

Una sola función recibe el lote de reseñas, corre los dos pipelines en batch y devuelve una estructura por reseña con el formato de la guía. Usa el modelo multilingüe de sentimiento (A.2) y el NER en español con **first** (B.3). Además de los campos pedidos, agrega **sentiment_raw** (la estrella) y **polarity_score**. El resultado completo se guarda en **resultados/laboratorio_4_resultados.json**.

```
def analizar_reseñas(textos, ids, sentiment_pipe, ner_pipe, batch_size=BATCH):
    sentimientos = sentiment_pipe(textos, batch_size=batch_size, truncation=True,
    ↪ top_k=None)
    entidades = ner_pipe(textos, batch_size=batch_size)

    salida = []
    for rid, texto, distribucion, ents in zip(ids, textos, sentimientos, entidades):
        polaridad, estrella, score, score_polaridad = resumir_distribucion(
    ↪ distribucion)
```

```

        salida.append({
            "review_id": int(rid),
            "text": texto,
            "sentiment": polaridad,
            "sentiment_score": round(score, 4),
            "sentiment_raw": estrella,
            "polarity_score": round(score_polaridad, 4),
            "entities": [
                {"label": e["entity_group"],
                 "text": texto[e["start"]:e["end"]],
                 "score": round(float(e["score"]), 4)}
                for e in ents
            ],
        })
    return salida

flujo = analizar_reseñas(reseñas, ids, sentiment_es, ner_es_first)

with open(RESULTADOS / "laboratorio_4_resultados.json", "w", encoding="utf-8") as f:
    json.dump(flujo, f, ensure_ascii=False, indent=2)

for registro in [flujo[i - 1] for i in (4, 18, 24)]:
    print(json.dumps(registro, ensure_ascii=False, indent=4))

```

Salida (tres de los 36 registros; las entidades se muestran en una línea cada una):

```

{
  "review_id": 4,
  "text": "Tres euros y medio por un café mediocre. Encima los baños estaban sucios a mediodía de un
    ↪ martes cualquiera. El FC Barcelona debería cuidar más sus instalaciones.",
  "sentiment": "NEGATIVE",
  "sentiment_score": 0.5659,
  "sentiment_raw": "1 star",
  "polarity_score": 0.9039,
  "entities": [
    {"label": "ORG", "text": "FC Barcelona", "score": 0.9995}
  ]
}
{
  "review_id": 18,
  "text": "Vinimos desde Guatemala solo para conocer el Spotify Camp Nou y comer aquí fue la guinda. Mi
    ↪ hijo Santiago salió feliz con su camiseta de Lamine Yamal.",
  "sentiment": "POSITIVE",
  "sentiment_score": 0.4784,
  "sentiment_raw": "5 stars",
  "polarity_score": 0.6749,
  "entities": [
    {"label": "LOC", "text": "Guatemala", "score": 0.9996},
    {"label": "MISC", "text": "Spotify Camp Nou", "score": 0.9308},
    {"label": "PER", "text": "Santiago", "score": 0.9986},
    {"label": "MISC", "text": "Lamine Yamal", "score": 0.9921}
  ]
}
{
  "review_id": 24,
  "text": "Celebramos el cumpleaños de mi sobrino Mateo aquí y el equipo del Barça Cafe se portó genial,
    ↪ hasta le pusieron una vela en el postre.",
  "sentiment": "POSITIVE",
  "sentiment_score": 0.2972,
  "sentiment_raw": "5 stars",
  "polarity_score": 0.5515,
  "entities": [
    {"label": "PER", "text": "Mateo", "score": 0.9991},
    {"label": "ORG", "text": "Barça Cafe", "score": 0.9995}
  ]
}

```

6. Parte D: estadísticas

La estructura integrada se aplanan en un `DataFrame` (una fila por reseña), se le agregan la etiqueta humana y la predicción del modelo por defecto, y se exporta como pide la guía.

```
df = pd.DataFrame([
    "review_id": r["review_id"],
    "text": r["text"],
    "etiqueta_humana": h,
    "casos": c,
    "sentiment": r["sentiment"],
    "sentiment_score": r["sentiment_score"],
    "sentiment_raw": r["sentiment_raw"],
    "polarity_score": r["polarity_score"],
    "sentiment_defecto": d_label,
    "score_defecto": d_score,
    "num_entities": len(r["entities"]),
    "entity_types": ";".join(sorted({e["label"] for e in r["entities"]})),
    "entities": " | ".join(f"{e['label']}:{e['text']} ({e['score']:.2f})" for e in r
    ↪ ["entities"]),
    for r, h, c, d_label, d_score in zip(flujo, df_resenas["etiqueta_humana"],
    ↪ df_resenas["casos"],
    ↪ df_sent_defecto["label"], df_sent_defecto["
    ↪ score"])]])

df.to_csv("laboratorio_4_resultados.csv", index=False)
print("Guardado laboratorio_4_resultados.csv -", df.shape)
df.drop(columns=["text", "casos"])
```

| Guardado laboratorio_4_resultados.csv - (36, 13)

Contenido de `laboratorio_4_resultados.csv`. “Mult.” es el modelo multilingüe (etiqueta, estrella, score y score de polaridad) y “Def.” el modelo por defecto:

ID	Hum.	Mult.	Est.	Score	Polar.	Def.	Score	Entidades (NER español, first)
1	POS	POS	5	0.857	0.992	POS	0.939	MISC:Museo del FC Barcelona
2	POS	POS	5	0.860	0.989	NEG	0.949	PER:Nuria
3	NEG	NEG	2	0.372	0.522	NEG	0.950	—
4	NEG	NEG	1	0.566	0.904	NEG	0.985	ORG:FC Barcelona
5	MIX	NEU	3	0.438	0.438	NEG	0.983	—
6	NEG	NEG	1	0.848	0.963	NEG	0.956	LOC:Barcelona
7	POS	POS	5	0.781	0.981	NEG	0.557	—
8	POS	POS	5	0.600	0.923	NEG	0.681	ORG:Barça; ORG:Real Madrid; MISC:Estrella Damm
9	NEG	POS	5	0.914	0.983	NEG	0.683	—
10	NEG	NEG	1	0.446	0.875	NEG	0.997	—
11	POS	NEU	3	0.446	0.446	NEG	0.995	LOC:Les Corts
12	POS	POS	5	0.841	0.974	POS	1.000	—
13	NEG	POS	5	0.324	0.544	POS	0.985	—
14	MIX	NEU	3	0.500	0.500	NEG	0.637	—
15	NEG	NEG	1	0.636	0.882	NEG	0.982	—
16	POS	POS	5	0.738	0.966	NEG	0.754	—

ID	Hum.	Mult.	Est.	Score	Polar.	Def.	Score	Entidades (NER español, first)
17	NEU	POS	5	0.323	0.583	NEG	0.570	LOC:Palau Blaugrana; LOC:calle Arístides Maillol
18	POS	POS	5	0.478	0.675	NEG	0.963	LOC:Guatemala; MISC:Spotify Camp Nou; PER:Santiago; MISC:Lamine Yamal
19	MIX	NEG	2	0.460	0.636	NEG	0.995	PER:Iglesias
20	NEG	NEG	2	0.448	0.708	NEG	0.896	—
21	POS	POS	4	0.637	0.695	POS	0.881	—
22	NEG	NEG	1	0.535	0.723	NEG	0.979	—
23	MIX	NEG	2	0.433	0.653	NEG	0.973	—
24	POS	POS	5	0.297	0.551	NEG	0.810	PER:Mateo; ORG:Barça Cafe
25	NEG	NEG	1	0.862	0.986	NEG	0.954	—
26	NEG	NEU	3	0.498	0.498	NEG	0.508	—
27	POS	NEG	2	0.559	0.820	NEG	0.977	—
28	NEG	NEU	3	0.460	0.460	POS	0.879	MISC:Museu del Barça; LOC:Catalunya
29	POS	NEG	1	0.326	0.577	NEG	0.984	MISC:Blaugrana Burger; MISC:Culé
30	POS	POS	5	0.827	0.989	POS	1.000	LOC:México
31	NEG	NEG	1	0.775	0.918	NEG	0.904	PER:Sergi
32	MIX	NEU	3	0.428	0.428	NEG	0.815	—
33	POS	POS	5	0.477	0.773	NEG	0.874	—
34	NEG	POS	5	0.945	0.974	POS	0.553	—
35	NEU	NEU	3	0.420	0.420	POS	0.880	—
36	POS	POS	5	0.461	0.834	POS	0.981	LOC:Japón; LOC:Brasil; MISC:Ambiente único; LOC:Barcelona

D.1 Reseñas por etiqueta y score promedio

```

por_etiqueta = (df.groupby("sentiment")
                .agg(reseñas=("sentiment_score", "count"), score_promedio=(
                    ↪ sentiment_score", "mean"),
                    score_min=("sentiment_score", "min"), score_max=(
                    ↪ sentiment_score", "max"),
                    polaridad_promedio=("polarity_score", "mean"))
                .round(4))
por_etiqueta_defecto = (df.groupby("sentiment_defecto")["score_defecto"]
                        .agg(reseñas="count", score_promedio="mean", score_min="min"
                            ↪ , score_max="max")
                        .round(4))

print("Modelo multilingüe (flujo integrado)")
print(por_etiqueta.to_string())
print(f"\nScore promedio global: {df['sentiment_score'].mean():.4f}    "
      f"(score de polaridad promedio: {df['polarity_score'].mean():.4f})")
print("\nModelo por defecto (inglés, SST-2)")
print(por_etiqueta_defecto.to_string())
print(f"\nScore promedio global: {df['score_defecto'].mean():.4f}")
print("\nDistribución de estrellas predichas:")
print(df["sentiment_raw"].value_counts().sort_index().to_string())

```

Salida:

Modelo	Etiqueta	Reseñas	Score prom.	Mín.	Máy.	Polaridad prom.
Multilingüe	NEGATIVE	13	0.5589	0.3262	0.8619	0.7821
Multilingüe	NEUTRAL	7	0.4558	0.4197	0.5005	0.4558
Multilingüe	POSITIVE	16	0.6475	0.2972	0.9452	0.8391

Modelo	Etiqueta	Reseñas	Score prom.	Mín.	Máx.	Polaridad prom.
Multilingüe	Global	36	0.5782			0.7440
Por defecto	NEGATIVE	27	0.8633	0.5080	0.9967	—
Por defecto	POSITIVE	9	0.8998	0.5527	0.9998	—
Por defecto	Global	36	0.8724			—

Estrellas predichas	1	2	3	4	5
Reseñas	8	5	7	1	15

El contraste es fuerte. El modelo por defecto manda 27 de 36 reseñas a **NEGATIVE** con un score promedio de 0.87. El multilingüe reparte 16/7/13 con un score promedio de 0.58, que sube a 0.74 al sumar la polaridad.

D.2 Las cinco reseñas de menor confianza

```
menor_confianza = df.nsmallest(5, "sentiment_score")[
    ["review_id", "text", "etiqueta_humana", "sentiment", "sentiment_raw", "
    ↳ sentiment_score", "polarity_score"]]
menor_confianza_defecto = df.nsmallest(5, "score_defecto")[
    ["review_id", "text", "etiqueta_humana", "sentiment_defecto", "score_defecto"]]

print("Multilingüe:")
display(menor_confianza)
print("Por defecto:")
display(menor_confianza_defecto)
```

Modelo multilingüe:

ID	Texto	Humano	Predicción	Score	Polaridad
24	Celebramos el cumpleaños de mi sobrino Mateo aquí y el equipo del Barça Cafe se portó genial, hasta le pusieron una vela en el postre.	POS	POS (5★)	0.2972	0.5515
17	Está junto al Palau Blaugrana, en la calle Arístides Maillol. Abren a las 10 de la mañana.	NEU	POS (5★)	0.3230	0.5834
13	Carísimo.	NEG	POS (5★)	0.3235	0.5436
29	La Blaugrana Burger con salsa Culé está brutal, pídala sin dudar.	POS	NEG (1★)	0.3262	0.5766
3	Pedí dos cafés y un croissant de chocolate y me lo sirvieron todo frío. Para estar dentro del estadio esperaba bastante más.	NEG	NEG (2★)	0.3717	0.5224

Modelo por defecto:

ID	Texto	Humano	Predicción	Score
26	Meh.	NEG	NEG	0.5080

ID	Texto	Humano	Predicción	Score
34	Cinco estrellas... para el aire acondicionado, que es lo único que funcionaba.	NEG	POS	0.5527
7	Un sitio precioso para visitar, la comida riquísima y el personal muy atento.	POS	NEG	0.5570
17	Está junto al Palau Blaugrana, en la calle Arístides Maillol. Abren a las 10 de la mañana.	NEU	NEG	0.5702
14	La decoración con camisetas firmadas y lámparas en forma de balón es preciosa, pero la comida es muy normalita y cara.	MIX	NEG	0.6372

En el multilingüe, tres de las cinco reseñas de menor confianza son errores (#17, #13 y #29): el score bajo sí avisa. La #24 acierta con el score más bajo del lote (0.30), pero sumando 4 y 5 estrellas su polaridad es 0.55. En el modelo por defecto la menos segura sigue teniendo 0.51, que es lo mínimo posible con dos clases.

D.3 Entidades

```
df_entidades = pd.DataFrame([
    {"review_id": r["review_id"], **e} for r in flujo for e in r["entities"]
])
df_entidades.to_csv(RESULTADOS / "d_entidades.csv", index=False)

print("NER en español con agregación first (flujo integrado)")
print(f"Entidades totales          : {len(df_entidades)}    (con 'simple' eran {
    ↪ len(df_ner_es)})")
print(f"Promedio de entidades por reseña: {df['num_entities'].mean():.2f}")
print(f"Reseñas con al menos una entidad: {(df['num_entities'] > 0).sum()} / {len(df
    ↪ )}")
print(f"Tipos de entidad encontrados   : {sorted(df_entidades['label'].unique())}\n
    ↪ ")

tipos = (df_entidades.groupby("label")
        .agg(entidades=("text", "count"), score_promedio=("score", "mean"),
            ejemplos=("text", lambda s: ", ".join(dict.fromkeys(s))))
        .round(4).sort_values("entidades", ascending=False))
tipos
```

```
NER en español con agregación first (flujo integrado)
Entidades totales          : 27    (con 'simple' eran 32)
Promedio de entidades por reseña: 0.75
Reseñas con al menos una entidad: 15 / 36
Tipos de entidad encontrados   : ['LOC', 'MISC', 'ORG', 'PER']
```

Tipo	Entidades	Score prom.	Ejemplos
LOC	10	0.9947	Barcelona, Les Corts, Palau Blaugrana, calle Arístides Maillol, Guatemala, Catalunya, México, Japón, Brasil
MISC	8	0.8866	Museo del FC Barcelona, Estrella Damm, Spotify Camp Nou, Lamine Yamal, Museu del Barça, Blaugrana Burger, Culé, Ambiente único
PER	5	0.9359	Nuria, Santiago, Iglesias, Mateo, Sergi
ORG	4	0.9774	FC Barcelona, Barça, Real Madrid, Barça Cafe

D.4 Precisión, recall y F1 contra la etiqueta humana

La etiqueta humana permite ir más allá del score. Se evalúan las 29 reseñas **polares** (humano = POSITIVO o NEGATIVO); una predicción **NEUTRAL** sobre una reseña polar cuenta como error. Con tan pocas reseñas las cifras son orientativas, no una evaluación formal.

```
from sklearn.metrics import classification_report, confusion_matrix

pol = df[df["etiqueta_humana"].isin(["POSITIVO", "NEGATIVO"])]
y_true = pol["etiqueta_humana"].map(MAPA_HUMANO)
metricas = []
for nombre, columna in [("defecto (SST-2 inglés)", "sentiment_defecto"), ("multiling
    ↪ ue (estrellas)", "sentiment")]:
    print(f"=== {nombre} ===")
    print(classification_report(y_true, pol[columna], labels=["POSITIVE", "NEGATIVE"]
    ↪ ), zero_division=0, digits=3))
    rep = classification_report(y_true, pol[columna], labels=["POSITIVE", "NEGATIVE"]
    ↪ ), zero_division=0, output_dict=True)
    metricas.append({"modelo": nombre, "accuracy": round((y_true == pol[columna]).
    ↪ mean(), 3),
                    **{f"{k}_{m}": round(rep[k][m], 3) for k in ("POSITIVE", "
    ↪ NEGATIVE") for m in ("precision", "recall", "f1-score")}})

etiquetas = ["POSITIVE", "NEUTRAL", "NEGATIVE"]
print("Matriz de confusión del multilingüe (filas = humano, columnas = modelo):")
print(pd.DataFrame(confusion_matrix(y_true, pol["sentiment"], labels=etiquetas),
    ↪ index=etiquetas, columns=etiquetas))

print("\n¿A dónde van las reseñas MIXTAS y NEUTRAS?")
print(df[df["etiqueta_humana"].isin(["MIXTO", "NEUTRO"])]["
    ↪ review_id", "etiqueta_humana", "sentiment_raw", "sentiment_score", "
    ↪ sentiment_defecto", "score_defecto"].to_string(index=False))

df_metricas = pd.DataFrame(metricas)
df_metricas
```

Salida resumida:

Métrica (29 reseñas polares)	Por defecto (SST-2)	Multilingüe (estrellas)
Accuracy	0.552	0.724
Precisión POSITIVE	0.625	0.800
Recall POSITIVE	0.333	0.800
F1 POSITIVE	0.435	0.800
Precisión NEGATIVE	0.524	0.818
Recall NEGATIVE	0.786	0.643
F1 NEGATIVE	0.629	0.720

Matriz de confusión del modelo multilingüe (filas = humano, columnas = modelo):

	POSITIVE	NEUTRAL	NEGATIVE
POSITIVE	12	1	2
NEUTRAL	0	0	0
NEGATIVE	3	2	9

Y las reseñas mixtas y neutras, que no entran en la métrica:

ID	Humano	Estrellas	Score	Defecto	Score def.
5	MIXTO	3 stars	0.4382	NEGATIVE	0.9827
14	MIXTO	3 stars	0.5005	NEGATIVE	0.6372
17	NEUTRO	5 stars	0.3230	NEGATIVE	0.5702
19	MIXTO	2 stars	0.4602	NEGATIVE	0.9948
23	MIXTO	2 stars	0.4334	NEGATIVE	0.9729
32	MIXTO	3 stars	0.4277	NEGATIVE	0.8152
35	NEUTRO	3 stars	0.4197	POSITIVE	0.8805

El recall de positivas del modelo por defecto (0.33) resume su problema: de cada tres reseñas positivas, dos las ve negativas. El multilingüe equilibra ambas clases. Su punto débil es el recall de negativas (0.64), porque tres negativas se le van a positivo: dos sarcasmos y “Carísimo.”.

D.5 ¿Un score alto significa acierto?

Se agrupan las reseñas polares por rango de score y se mide el porcentaje de aciertos en cada rango. Si el score estuviera bien calibrado (Guo et al., 2017), el acierto subiría con el score.

```

rangos = [0, 0.5, 0.8, 1.0]
filas = []
for nombre, pred, score in [("defecto", "sentiment_defecto", "score_defecto"),
                             ("multilingüe (estrella)", "sentiment", "sentiment_score"),
                             ("multilingüe (polaridad)", "sentiment", "polarity_score")]:
    tmp = pol.assign(acierto=pol[pred] == y_true, rango=pd.cut(pol[score], rangos))
    for rango, g in tmp.groupby("rango", observed=False):
        filas.append({"modelo": nombre, "rango_score": str(rango), "reseñas": len(g),
                      "aciertos": int(g["acierto"].sum()),
                      "tasa_acierto": round(g["acierto"].mean(), 3) if len(g) else
                      None})
calibracion = pd.DataFrame(filas)
calibracion.to_csv(REULTADOS / "d_calibracion_score.csv", index=False)
display(calibracion)

print("Las 3 predicciones con mayor score del modelo multilingüe:")
df.nlargest(3, "sentiment_score")[["review_id", "text", "etiqueta_humana", "sentiment", "sentiment_score"]]

```

Modelo	Rango de score	Reseñas	Aciertos	Tasa de acierto
defecto	(0.0, 0.5]	0	0	—
defecto	(0.5, 0.8]	6	2	0.333
defecto	(0.8, 1.0]	23	14	0.609
multilingüe (estrella)	(0.0, 0.5]	12	7	0.583
multilingüe (estrella)	(0.5, 0.8]	9	8	0.889
multilingüe (estrella)	(0.8, 1.0]	8	6	0.750
multilingüe (polaridad)	(0.0, 0.5]	3	0	0.000
multilingüe (polaridad)	(0.5, 0.8]	9	7	0.778
multilingüe (polaridad)	(0.8, 1.0]	17	14	0.824

Las tres predicciones con mayor score del modelo multilingüe:

ID	Texto	Humano	Predicción	Score
34	Cinco estrellas... para el aire acondicionado, que es lo único que funcionaba.	NEG	POS	0.9452
9	Genial, 40 minutos esperando una hamburguesa que llegó fría. Una experiencia inolvidable, de verdad.	NEG	POS	0.9141
25	Personal desbordado, música altísima y nadie limpió nuestra mesa en toda la tarde. Una pena para la imagen del club.	NEG	NEG	0.8619

Este es probablemente el resultado más importante del laboratorio. En el modelo por defecto, de las 23 predicciones con score mayor a 0.8 solo acierta el 61 %. En el multilingüe, las **dos predicciones más seguras de todo el lote son errores**: los dos sarcasmos. Con la suma por polaridad el comportamiento es más sensato: 82 % de acierto arriba de 0.8 y 0 % por debajo de 0.5, aunque ese rango solo tiene tres reseñas.

```

resumen = pd.DataFrame([
    ("reseñas", len(df)),
    ("positivas (multilingüe)", int((df["sentiment"] == "POSITIVE").sum())),
    ("negativas (multilingüe)", int((df["sentiment"] == "NEGATIVE").sum())),
    ("neutras (multilingüe)", int((df["sentiment"] == "NEUTRAL").sum())),
    ("score promedio (multilingüe)", round(df["sentiment_score"].mean(), 4)),
    ("positivas (defecto)", int((df["sentiment_defecto"] == "POSITIVE").sum())),
    ("negativas (defecto)", int((df["sentiment_defecto"] == "NEGATIVE").sum())),
    ("score promedio (defecto)", round(df["score_defecto"].mean(), 4)),
    ("accuracy polares (defecto)", df_metricas.loc[0, "accuracy"]),
    ("accuracy polares (multilingüe)", df_metricas.loc[1, "accuracy"]),
    ("entidades totales", len(df_entidades)),
    ("entidades promedio por reseña", round(df["num_entities"].mean(), 2)),
    ("tipos de entidad", ";".join(sorted(df_entidades["label"].unique()))),
], columns=["metrica", "valor"])
resumen.to_csv(RESULTADOS / "d_resumen_estadisticas.csv", index=False)
df_metricas.to_csv(RESULTADOS / "d_metricas_sentimiento.csv", index=False)
resumen

```

Métrica	Valor
reseñas	36
positivas (multilingüe)	16
negativas (multilingüe)	13
neutras (multilingüe)	7
score promedio (multilingüe)	0.5782
positivas (defecto)	9
negativas (defecto)	27
score promedio (defecto)	0.8724
accuracy polares (defecto)	0.552
accuracy polares (multilingüe)	0.724
entidades totales	27
entidades promedio por reseña	0.75
tipos de entidad	LOC;MISC;ORG;PER

```

fig, ejes = plt.subplots(1, 3, figsize=(16, 4.2))
orden = ["POSITIVE", "NEUTRAL", "NEGATIVE"]
colores = {"POSITIVE": "#2e7d32", "NEUTRAL": "#9e9e9e", "NEGATIVE": "#c62828"}


conteo = pd.DataFrame({
    "humano": df["etiqueta_humana"].map(MAPA_HUMANO).replace({"MIXED": "NEUTRAL"}).
        ↪ value_counts(),
    "defecto": df["sentiment_defecto"].value_counts(),
    "multilingüe": df["sentiment"].value_counts(),
}).reindex(orden).fillna(0)
conteo.T.plot(kind="bar", stacked=True, color=[colores[c] for c in orden], ax=ejes
    ↪ [0], rot=0)
ejes[0].set_title("Reseñas por etiqueta (humano: mixto cuenta como neutro)")
ejes[0].legend(ncol=3, loc="upper center", fontsize=9)
ejes[0].set_ylim(0, 42)
ejes[0].set_ylabel("reseñas")

ejes[1].hist([df["score_defecto"], df["sentiment_score"]], bins=10, range=(0.2, 1),
    label=["defecto (2 clases)", "multilingüe (5 estrellas)"], color=["
    ↪ #78909c", "#1565c0"])
ejes[1].set_title("Distribución del score de confianza")
ejes[1].set_xlabel("score")
ejes[1].legend()

tipos["entidades"].plot(kind="bar", ax=ejes[2], color="#6a1b9a", rot=0)
ejes[2].set_title("Entidades por tipo (NER español)")
ejes[2].set_xlabel("")

plt.tight_layout()
plt.savefig(FIGURAS / "d_resumen.png", dpi=130, bbox_inches="tight")
plt.show()

```



7. Parte E: análisis de casos difíciles

Se eligieron **nueve** reseñas que cubren los tipos de dificultad de la guía: sarcasmo, negación, opinión mixta, texto muy corto, entidad desconocida, errores ortográficos y score bajo. Para cada una se registran la predicción, la interpretación humana, si coinciden y la posible causa del error. *Coinciden* se mide contra el flujo integrado (modelo multilingüe). Si la etiqueta humana es mixta, cuenta como acierto **NEUTRAL**; si el modelo o el humano dicen neutro sin coincidir, se marca como parcial.

```
import textwrap

CASOS_DIFICILES = {
    # review_id: (tipo de dificultad, interpretación humana, posible causa del error
    # ↪ )
    9: ("Sarcasmo",
        "NEGATIVO. Queja por 40 minutos de espera y comida fría; 'genial' e '
        ↪ inolvidable' son ironía.",
        "Pesan las palabras positivas ('Genial', 'inolvidable') y el modelo no
        ↪ detecta que chocan con "
        "los hechos narrados (40 minutos, llegó fría). Reconocer ironía exige
        ↪ razonamiento pragmático "
        "que un clasificador entrenado con reseñas literales no aprende."),
    # ... 8 casos más con la misma estructura; sus textos completos están
    # en las tablas de abajo y en resultados/e_casos_dificiles.csv
}

def coincidencia(humano, modelo):
    h = MAPA_HUMANO[humano]
    if h == modelo or (h == "MIXED" and modelo == "NEUTRAL"):
        return "Sí"
    if h == "MIXED" or "NEUTRAL" in (h, modelo):
        return "Parcial"
    return "No"

por_id = df.set_index("review_id")
filas = []
for rid, (tipo, humano, causa) in CASOS_DIFICILES.items():
    r = por_id.loc[rid]
    filas.append({
        "review_id": rid,
        "tipo": tipo,
        "text": r["text"],
        "prediccion": f"{r['sentiment']} ({r['sentiment_raw']}, {r['sentiment_score"]
```

```

↪ ']:.3f}}",
    "score_polaridad": r["polarity_score"],
    "prediccion_defecto": f"{r['sentiment_defecto']} ({r['score_defecto']:.3f})"
↪ ,
    "entidades": r["entities"] or "-",
    "interpretacion_humana": humano,
    "coincide": coincidencia(r["etiqueta_humana"], r["sentiment"]),
    "coincide_defecto": coincidencia(r["etiqueta_humana"], r["sentiment_defecto"])
↪ ]),
    "posible_causa": causa,
})

casos = pd.DataFrame(filas)
casos.to_csv(RESULTADOS / "e_casos_dificiles.csv", index=False)

print("Coincidencia con la interpretación humana")
print(" multilingüe:", casos["coincide"].value_counts().to_dict())
print(" defecto      :", casos["coincide_defecto"].value_counts().to_dict())
casos[["review_id", "tipo", "text", "prediccion", "score_polaridad", "
↪ prediccion_defecto", "coincide", "coincide_defecto"]]

```

```

Coincidencia con la interpretación humana
multilingüe: {'No': 5, 'Parcial': 3, 'Sí': 1}
defecto      : {'No': 7, 'Sí': 1, 'Parcial': 1}

```

ID	Tipo	Predicción (multilingüe)	Defecto	Coincide	Coincide def.
9	Sarcasmo	POSITIVE (5★, 0.914)	NEGATIVE (0.683)	No	Sí
34	Sarcasmo con ancla léxica	POSITIVE (5★, 0.945)	POSITIVE (0.553)	No	No
27	Doble negación	NEGATIVE (2★, 0.559)	NEGATIVE (0.977)	No	No
11	Negación con sentido positivo (litote)	NEUTRAL (3★, 0.446)	NEGATIVE (0.995)	Parcial	No
23	Opinión mixta	NEGATIVE (2★, 0.433)	NEGATIVE (0.973)	Parcial	Parcial
13	Texto muy corto	POSITIVE (5★, 0.324)	POSITIVE (0.985)	No	No
29	Entidad desconocida + jerga	NEGATIVE (1★, 0.326)	NEGATIVE (0.984)	No	No
16	Errores ortográficos	POSITIVE (5★, 0.738)	NEGATIVE (0.754)	Sí	No
28	Negatividad implícita + NER	NEUTRAL (3★, 0.460)	POSITIVE (0.879)	Parcial	No

La celda siguiente del notebook imprime cada caso en detalle. Aquí va en forma de tabla:

#9 · Sarcasmo	
Reseña	<i>Genial, 40 minutos esperando una hamburguesa que llegó fría. Una experiencia inolvidable, de verdad.</i>
Predicción	POSITIVE (5 estrellas, 0.914); score de polaridad 0.983
Modelo por defecto	NEGATIVE (0.683)
Entidades	—
Interpretación humana	NEGATIVO. Queja por 40 minutos de espera y comida fría; ‘genial’ e ‘inolvidable’ son ironía.
¿Coinciden?	No
Posible causa	Pesan las palabras positivas (‘Genial’, ‘inolvidable’) y el modelo no detecta que chocan con los hechos narrados (40 minutos, llegó fría). Reconocer ironía exige razonamiento pragmático que un clasificador entrenado con reseñas literales no aprende.

#34 · Sarcasmo con ancla léxica	
Reseña	<i>Cinco estrellas... para el aire acondicionado, que es lo único que funcionaba.</i>
Predicción	POSITIVE (5 estrellas, 0.945); score de polaridad 0.974
Modelo por defecto	POSITIVE (0.553)
Entidades	—
Interpretación humana	NEGATIVO. Las ‘cinco estrellas’ son para el aire acondicionado, lo único que funcionaba.
¿Coinciden?	No
Posible causa	‘Cinco estrellas’ es casi literalmente la etiqueta ‘5 stars’ con la que se entrenó; en reseñas reales esa frase casi siempre acompaña a una nota de 5. Lo más probable es que el modelo haya aprendido ese atajo y no procese el giro ‘...para el aire acondicionado’.

#27 · Doble negación	
Reseña	<i>No puedo decir que no me haya gustado: el bocadillo de jamón estaba bueno y no tardaron nada.</i>
Predicción	NEGATIVE (2 estrellas, 0.559); score de polaridad 0.820
Modelo por defecto	NEGATIVE (0.977)
Entidades	—
Interpretación humana	POSITIVO. ‘No puedo decir que no me haya gustado’ equivale a ‘me gustó’; ‘no tardaron nada’ es un elogio.
¿Coinciden?	No
Posible causa	Tres marcadores negativos (‘no’, ‘no’, ‘nada’) que el modelo parece sumar como señales negativas en lugar de componerlos: dos negaciones se cancelan y ‘no tardaron nada’ es positivo.

#11 · Negación con sentido positivo (litote)	
Reseña	<i>No está nada mal para ser un sitio turístico. Las bravas no tienen nada que envidiar a las de cualquier bar de Les Corts.</i>
Predicción	NEUTRAL (3 estrellas, 0.446); score de polaridad 0.446
Modelo por defecto	NEGATIVE (0.995)
Entidades	LOC:Les Corts (1.00)
Interpretación humana	POSITIVO. ‘No está nada mal’ y ‘no tienen nada que envidiar’ son elogios.
¿Coinciden?	Parcial
Posible causa	Acumula ‘no’, ‘nada’, ‘mal’ y ‘envidiar’. El modelo duda (3 estrellas) y no llega a invertir la polaridad: sumando 4 y 5 estrellas la probabilidad positiva es 0.48, apenas por encima del 0.45 neutro.

#23 · Opinión mixta	
Reseña	<i>Los camareros son un amor, pero la cocina es un desastre: el pollo seco y las patatas congeladas.</i>
Predicción	NEGATIVE (2 estrellas, 0.433); score de polaridad 0.653
Modelo por defecto	NEGATIVE (0.973)
Entidades	—
Interpretación humana	MIXTO. Servicio excelente (‘un amor’) y cocina muy mala (‘un desastre’).
¿Coinciden?	Parcial
Posible causa	Una sola etiqueta no puede expresar dos aspectos opuestos. El modelo pesa más la cláusula que sigue al ‘pero’ y da 2 estrellas; el score bajo refleja la mezcla. Haría falta análisis de sentimiento por aspectos (servicio / comida / precio; Pontiki et al., 2014).

#13 · Texto muy corto	
Reseña	<i>Carísimo.</i>
Predicción	POSITIVE (5 estrellas, 0.324); score de polaridad 0.544
Modelo por defecto	POSITIVE (0.985)
Entidades	—
Interpretación humana	NEGATIVO. Una sola palabra que critica el precio.
¿Coinciden?	No
Posible causa	Sin contexto, y con un vocabulario multilingüe que trocea la palabra en ‘car’ + ‘##isi’ + ‘##mo’, el modelo no tiene señal. Su score es de los más bajos del lote: avisa que no sabe. El modelo por defecto, en cambio, se equivoca con 0.985.

#29 · Entidad desconocida + jerga	
Reseña	<i>La Blaugrana Burger con salsa Culé está brutal, pídanla sin dudar.</i>
Predicción	NEGATIVE (1 estrella, 0.326); score de polaridad 0.577
Modelo por defecto	NEGATIVE (0.984)
Entidades	MISC:Blaugrana Burger (1.00); MISC:Culé (1.00)
Interpretación humana	POSITIVO. En España ‘brutal’ significa ‘buenísimo’; ‘Blaugrana Burger’ y ‘salsa Culé’ son productos.
¿Coinciden?	No
Posible causa	El sentido normativo de ‘brutal’ (cruel, violento), que coincide con el inglés, es negativo y probablemente es el que dominó en el entrenamiento. Los nombres inventados no aportan señal. En NER, con ‘simple’ ‘Culé’ salía partido en ‘Cul’ + ‘é’; con ‘first’ ambos productos quedan como MISC.

#16 · Errores ortográficos	
Reseña	<i>q buen sitio!! los nachos buenisimos y el camarero super atento, bolveremos seguro</i>
Predicción	POSITIVE (5 estrellas, 0.738); score de polaridad 0.966
Modelo por defecto	NEGATIVE (0.754)
Entidades	—
Interpretación humana	POSITIVO. Elogio claro pese a ‘q’, ‘buenisimos’ y ‘bolveremos’.
¿Coinciden?	Sí
Posible causa	Coincide. Las faltas no borran las señales fuertes (‘buen sitio’, ‘super atento’, ‘!!’) y el modelo es uncased y quita acentos, así que ‘buenisimos’ y ‘buenísimos’ se tokenizan igual. El modelo por defecto falla porque no conoce el español.

#28 · Negatividad implícita + NER	
Reseña	<i>Esperaba algo digno del Museu del Barça y me encontré un bar de aeropuerto con precios de Plaça de Catalunya.</i>
Predicción	NEUTRAL (3 estrellas, 0.460); score de polaridad 0.460
Modelo por defecto	POSITIVE (0.879)
Entidades	MISC:Museu del Barça (0.69); LOC:Catalunya (0.97)
Interpretación humana	NEGATIVO. Compara el local con un bar de aeropuerto con precios de zona turística.
¿Coinciden?	Parcial
Posible causa	No hay palabras negativas: la crítica está en la comparación, y entenderla requiere saber que un ‘bar de aeropuerto’ es caro y mediocre. El modelo queda en 3 estrellas. En NER, ‘Plaça de Catalunya’ se reduce a ‘Catalunya’ y con ‘simple’ ‘Museu’ salía partido en ‘Muse’ + ‘u’.

Patrones que dejan los casos difíciles

1. **El score no protege contra el sarcasmo.** Las dos predicciones con mayor score de todo el lote (#34 con 0.945 y #9 con 0.914) son sarcasmos clasificados como 5 estrellas. El modelo está más seguro justo cuando más se equivoca.
2. **La negación se lee como vocabulario, no como operador.** “No está nada mal” (#11) y “no puedo decir que no me haya gustado” (#27) contienen varias palabras negativas y el modelo las acumula en vez de invertir su efecto. El modelo por defecto falla las dos con scores de 0.99 y 0.98.
3. **Cuando falta señal, el modelo sí lo avisa.** En el texto de una palabra (#13), en la reseña informativa (#17) y en la crítica implícita (#28) el score cae por debajo de 0.5. En esos casos el score funciona como alarma útil.
4. **Robusto a faltas, frágil ante la jerga.** Las reseñas con errores ortográficos (#15 y #16) se clasifican bien, pero una sola palabra de uso regional (“brutal”, #29) invierte la predicción.
5. **En NER hay dos tipos de error.** Los de *agregación* (entidades partidas en subpalabras) desaparecen con `first`. Los de *etiquetado* se quedan: una persona pública marcada como MISC, una entidad truncada y un falso positivo por mayúscula inicial.

8. Preguntas de reflexión

1. ¿El modelo parece apropiado para reseñas en español?

El modelo por defecto, no. distilbert-base-uncased-finetuned-sst-2-english se entrenó con reseñas de cine en inglés. Sobre las 36 reseñas predijo **NEGATIVE** en 27, acertó el **55 %** de las polares (apenas mejor que una moneda) y solo reconoció **1 de cada 3** positivas (recall 0.33). Sus predicciones positivas más seguras son justo las dos reseñas

con palabras en inglés (“Top!!” y “Amazing... very friendly”, ambas con 0.9998). Lo más problemático es que falla con seguridad: su score promedio es 0.87.

El modelo multilingüe es aceptable como primer filtro, pero no es ideal. `nlptown/bert-base-multilingual-uncased-sentiment` sí vio reseñas en español y llega al **72%** de acierto, con F1 de 0.80 en positivas y 0.72 en negativas. Aun así se entrenó con reseñas de *producto*, no de restaurantes, y no conoce la jerga de España. El siguiente paso sería un modelo nativo en español (en una prueba exploratoria con seis frases, `pysentimiento/robertuito-sentiment-analysis` (Pérez et al., 2021) resolvió mejor “no está mal” pero también cayó en el sarcasmo) o, mejor, afinar con unos cientos de reseñas de restaurantes etiquetadas.

2. ¿Qué errores de sentimiento encontraste?

- **Sarcasmo** clasificado como positivo y con el score más alto del lote (#9, #34).
- **Negación compuesta:** litote (#11 → 3 ★) y doble negación (#27 → 2 ★).
- **Jerga regional:** “está brutal” leído como negativo (#29 → 1 ★).
- **Texto muy corto:** “Carísimo.” → 5 ★ (#13), aunque con score bajo.
- **Reseña informativa** sin opinión (#17) → 5 ★. El modelo no tiene clase “sin opinión”: todas las reseñas con las que se entrenó valoran algo.
- **Crítica implícita** por comparación (#28 → 3 ★).
- **Mixtas:** tres de cinco caen en 3 ★ y dos en 2 ★. Es razonable, pero pierde el aspecto positivo.
- **Sesgo del modelo por defecto:** casi todo lo que no entiende lo manda a **NEGATIVE**, y así acierta negativas “por accidente”.

3. ¿Qué problemas observaste en NER?

- **Fragmentación en subpalabras** con `aggregation_strategy="simple"`: 8 fragmentos de 32 entidades en el modelo en español (`Nu+ria`, `Spo+tify Camp Nou`) y 22 de 46 en el modelo por defecto. Con `first` bajan a 0.
- **Falsos positivos del modelo en inglés** sobre palabras en mayúscula o trozos de palabras: `del` → LOC, `ca` → PER, `Me` (de “Meh.”) → PER, `Carís` → ORG, y `mb/ues` → MISC dentro de “hamburguesa(s)” (posiblemente por su parecido con *Hamburg*).
- **Tipo equivocado:** Lamine Yamal sale como MISC y no como PER.
- **Entidades truncadas:** `Plaça de Catalunya` → Catalunya; de “los hermanos Iglesias” solo queda Iglesias, que además es un sustantivo común.
- **Mayúscula = entidad:** Ambiente único se marca MISC solo por empezar oración.
- **Categorías que no encajan en el dominio:** CoNLL-2002 son noticias. No existe una clase para platos o productos (`Blaugrana Burger` cae en MISC), y `Spotify Camp Nou` es a la vez estadio (LOC) y marca patrocinada (ORG), así que el modelo lo manda a MISC.

- **Lo que funcionó:** los cuatro nombres ficticios de personas (Nuria, Santiago, Mateo, Sergi) y las organizaciones y países se detectaron, todos con score superior a 0.9.

4. ¿Cómo influye el score en tu confianza?

El score es la probabilidad softmax de la clase ganadora, **no la probabilidad de acertar**.

- En el modelo por defecto, de las 23 predicciones polares con score > 0.8 solo acertó el **61 %**.
- En el multilingüe, el rango de score > 0.8 acierta menos (75 %) que el de 0.5–0.8 (89 %), porque ahí están los dos sarcasmos.
- Con cinco clases el score de la estrella ganadora **subestima** la confianza: #24 es claramente positiva, acierta y tiene 0.30, porque el resto de la probabilidad se fue a 4 estrellas. Sumando la polaridad sube a 0.55. Ese `score_polaridad` se comporta mejor: 82 % de acierto por encima de 0.8 y 0 % por debajo de 0.5 (aunque ese rango solo tiene 3 reseñas).

Conclusión: **un score bajo es una buena alarma** para mandar la reseña a revisión humana, pero **un score alto no es garantía**. Además no es comparable entre modelos con distinto número de clases, y saber si está calibrado exige datos etiquetados.

5. ¿Qué datos etiquetarías manualmente para calcular precision, recall y F1?

Sentimiento

- Una muestra **estratificada** de reseñas reales: todas las estrellas, idiomas y longitudes, y sobremuestreo de los casos difíciles (sarcasmo, negación, mixtas), porque son raros pero caros.
- Al menos 200–300 reseñas, para tener unas 30 por clase aun con la distribución real, que es muy polarizada (176 / 33 / 34 / 44 / 137).
- Etiquetas POSITIVO / NEGATIVO / NEUTRO / MIXTO y marcas de fenómeno, asignadas por **dos anotadores** con una guía escrita, midiendo su acuerdo (kappa de Cohen, 1960). Las estrellas del usuario sirven como señal débil, pero no reemplazan la etiqueta: la nota y el texto no siempre coinciden.
- Reportar **F1 macro**, porque las clases están desbalanceadas.

En este laboratorio ya se hizo una versión mínima: la columna `etiqueta_humana` permitió calcular las métricas de la Parte D.4.

NER

- Spans exactos con su tipo, siguiendo una guía que decida de antemano los casos ambiguos: estadio = LOC, Barça Cafe = ORG, platos = una clase PRODUCTO nueva y figuras públicas = PER.
- Evaluación **a nivel de entidad** (coincidencia exacta de span y tipo, como `segeval`; Nakayama, 2018), y aparte las coincidencias parciales para cuantificar las truncaciones (Catalunya vs. Plaça de Catalunya).

6. ¿Usarías estas predicciones para tomar decisiones automáticas importantes? ¿Por qué?

No.

- El 72 % de acierto sale de 29 reseñas: la muestra es pequeña y el margen de error, amplio.
- Los errores **no son aleatorios**: se concentran en sarcasmo y negación, que abundan justo en las reseñas enojadas, las que más importan.
- Los errores más graves llegan con score alto, así que un umbral de confianza no los filtra.
- El NER extrae nombres de empleados (“el encargado Sergi”). Tomar decisiones sobre personas a partir de eso tiene implicaciones laborales y de privacidad.

Sí lo usaría como **apoyo**, con una persona en el circuito:

- **Tendencias agregadas**, por ejemplo el porcentaje de reseñas negativas por mes o por tema. Ahí los errores individuales se compensan y basta con una auditoría humana periódica.
- **Triaje**: mandar a revisión humana primero lo **NEGATIVE** o con score de polaridad bajo.

No lo usaría para responder públicamente de forma automática, borrar reseñas, fijar precios ni evaluar o sancionar a un empleado mencionado.

Conclusiones

1. **El modelo por defecto no es una opción para español.** La llamada literal de la guía elige un modelo de reseñas de cine en inglés. Acierta el 55 % de las reseñas polares, marca como negativas 27 de 36 y lo hace con un score promedio de 0.87. Hay que elegir el modelo explícitamente.
2. **Un modelo multilingüe entrenado con reseñas mejora mucho, pero falla donde más importa.** Llega al 72 % de acierto, con F1 de 0.80 y 0.72, y sus errores no son aleatorios: se concentran en sarcasmo, negación compuesta y jerga, que abundan en las reseñas enojadas.
3. **El score sirve como alarma, no como garantía.** Un score bajo sí señala dudas (tres de las cinco reseñas menos seguras son errores). Pero las dos predicciones más seguras del lote son sarcasmos mal clasificados. Con cinco clases conviene sumar la probabilidad por polaridad antes de interpretarlo.
4. **En NER, la configuración pesa tanto como el modelo.** Cambiar la estrategia de agregación de **simple** a **first** eliminó los ocho fragmentos de subpalabras sin tocar el modelo. Los errores que quedan (tipo equivocado, entidades truncadas, falsos positivos por mayúscula) sí requieren datos del dominio para corregirse.

Referencias

- Cañete, J., Chaperon, G., Fuentes, R., Ho, J.-H., Kang, H., & Pérez, J. (2020). *Spanish pre-trained BERT model and evaluation data*. PML4DC Workshop at ICLR 2020. <https://github.com/dccuchile/beto>
- Cohen, J. (1960). A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, 20(1), 37–46. <https://doi.org/10.1177/001316446002000104>
- Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. En *Proceedings of NAACL-HLT 2019* (pp. 4171–4186). Association for Computational Linguistics. <https://doi.org/10.18653/v1/N19-1423>
- FC Barcelona. (2021). *Barça Cafe, the new emblematic restaurant at Camp Nou*. <https://www.fcbarcelona.com/en/news/2139272/barca-cafe-the-new-emblematic-restaurant-at-camp-nou>
- Google. (s.f.). *Barça Cafe* [Ficha y opiniones en Google Maps]. Recuperado el 14 de septiembre de 2026 de <https://www.google.com/maps/search/Barca+Cafe+Barcelona>
- Guo, C., Pleiss, G., Sun, Y., & Weinberger, K. Q. (2017). On calibration of modern neural networks. En *Proceedings of the 34th International Conference on Machine Learning* (pp. 1321–1330). PMLR.
- Hugging Face. (s.f.). *Pipelines: TokenClassificationPipeline*. Transformers Documentation. https://huggingface.co/docs/transformers/main_classes/pipelines
- Nakayama, H. (2018). *segeval: A Python framework for sequence labeling evaluation* [Software]. <https://github.com/chakki-works/segeval>
- NLP Town. (s.f.). *bert-base-multilingual-uncased-sentiment* [Modelo]. Hugging Face. <https://huggingface.co/nlptown/bert-base-multilingual-uncased-sentiment>
- Pérez, J. M., Rajngewerc, M., Giudici, J. C., Furman, D. A., Luque, F., Alonso Alemany, L., & Martínez, M. V. (2021). *pysentimiento: A Python toolkit for opinion mining and social NLP tasks*. arXiv. <https://arxiv.org/abs/2106.09462>
- Pontiki, M., Galanis, D., Pavlopoulos, J., Papageorgiou, H., Androutsopoulos, I., & Manandhar, S. (2014). SemEval-2014 Task 4: Aspect based sentiment analysis. En *Proceedings of the 8th International Workshop on Semantic Evaluation* (pp. 27–35). Association for Computational Linguistics. <https://doi.org/10.3115/v1/S14-2004>
- Romero, M. (s.f.). *bert-spanish-cased-finetuned-ner* [Modelo]. Hugging Face. <https://huggingface.co/mrm8488/bert-spanish-cased-finetuned-ner>
- Sanh, V., Debut, L., Chaumond, J., & Wolf, T. (2019). *DistilBERT, a distilled version of BERT: Smaller, faster, cheaper and lighter*. arXiv. <https://arxiv.org/abs/1910.01108>
- Socher, R., Perelygin, A., Wu, J., Chuang, J., Manning, C. D., Ng, A., & Potts, C. (2013). Recursive deep models for semantic compositionality over a sentiment treebank. En *Proceedings of the 2013 Conference on Empirical Methods in Natural Language Pro-*

- cessing* (pp. 1631–1642). Association for Computational Linguistics.
- Tjong Kim Sang, E. F. (2002). Introduction to the CoNLL-2002 shared task: Language-independent named entity recognition. En *Proceedings of CoNLL-2002*. <https://aclanthology.org/W02-2024/>
- Tjong Kim Sang, E. F., & De Meulder, F. (2003). Introduction to the CoNLL-2003 shared task: Language-independent named entity recognition. En *Proceedings of CoNLL-2003* (pp. 142–147). <https://aclanthology.org/W03-0419/>
- Wolf, T., Debut, L., Sanh, V., Chaumond, J., Delangue, C., Moi, A., Cistac, P., Rault, T., Louf, R., Funtowicz, M., Davison, J., Shleifer, S., von Platen, P., Ma, C., Jernite, Y., Plu, J., Xu, C., Le Scao, T., Gugger, S., . . . Rush, A. (2020). Transformers: State-of-the-art natural language processing. En *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations* (pp. 38–45). Association for Computational Linguistics. <https://doi.org/10.18653/v1/2020.emnlp-demos.6>